

Prueba técnica: Científico de Datos, Riesgo de Crédito - Nequi

Emanuelle Alejandro Moreno Quintero - morenoemanuel98@gmail.com

Resumen ejecutivo (para stakeholders)

¿Qué propongo? Un modelo tipo scorecard (regresión logística) con solo tres variables: recargas mensuales promedio, porcentaje de pagos a tiempo de servicios públicos y telefonía, y si el cliente tiene historial en buró. Estima la probabilidad de que un crédito llegue a 60 días de mora o más durante sus primeros 90 días.

¿Qué tan bueno es? Ordena bien a los clientes. En clientes que el modelo nunca vio (648 créditos de nov-dic 2024) obtuvo AUC 0.78 y KS 0.47. El 10% de clientes más riesgoso tiene 38.5% de default y el 10% más seguro 1.5%. Aprobando al 60% de menor riesgo (corte fijado con datos anteriores), el default entre aprobados es 3.8% frente a 14.4% del total. También funciona para quienes no tienen buró (AUC 0.79), el 55% de los solicitantes.

Riesgos.

- Desde octubre de 2024 los clientes pagan peor sus servicios (de 75% a 68% a tiempo) y el default sube de 9.6% a 14.4%. El modelo sigue ordenando, pero subestima el nivel (predice 12.5%, real 14.4%).
- El 11% de los créditos (434) ya está en mora en su primer corte y concentra el 57% de los defaults: parece fraude o falta de intención de pago más que riesgo de crédito.
- Hay pocos defaults (93 en la muestra final), por lo que el AUC real podría estar entre 0.73 y 0.82.

Recomendación. Piloto controlado con exposición limitada, corte de aprobación sobre la probabilidad recalibrada, controles de identidad y primer pago contra el fraude temprano, y monitoreo mensual (alerta si el PSI supera 0.10) para recalibrar o reentrenar.

Respuestas a las preguntas de criterio

1. ¿Qué criterio usé para construir el default y cómo cambiaría la tasa con otro umbral?

Construí una fila por crédito a partir del panel (3.930 créditos desembolsados). Marqué **default = 1** si la mora máxima en los **primeros 3 cortes mensuales (90 días)** es de **60 días o más**. Unifiqué los niveles sobre 90 (91 a 120, 319 registros) como "90+".

Umbral. Con la matriz de transición, mora 30 no es default porque el 51.8% se cura; en mora 60, el 89.5% pasa a 90+ y solo el 10.5% regresa a 30. Es el primer nivel desde el que casi nadie se recupera y deja suficientes eventos. Tasas con la misma ventana: **mora ≥ 30 : 28.5%** (1.118 eventos), **≥ 60 : 10.6%** (415) y **≥ 90 : 5.1%** (202). Con 90 quedan muy pocos eventos para partir en tres bases y con 30 se mezclan clientes que se curan.

Fechas de apertura. Los créditos abiertos más tarde tienen menos cortes observados: solo 2.938 tienen 4 cortes, 1.937 tienen 5 y 953 tienen 6. Si se mira "alguna vez en mora 60" a lo largo de toda la historia la tasa es 15.6% y mezcla créditos con distinto tiempo de vida. Fijé la ventana en 3 cortes para que todos se observen lo mismo y no excluir créditos: con 4 cortes se perdía el 25% de la base y la tasa bajaba artificialmente a 9.1%, porque los créditos con solo 3 cortes son los más riesgosos (14.8% llega a 60, contra 7.9% a 10.2% de los demás).

2. ¿Qué particularidades encontré?

- **Formatos de fecha mezclados:** 20 créditos con fecha_apertura en DD-MM-AAAA y un bloque de application_date con día de un dígito (D/MM/AA). Los detecté y estandaricé a AAAA-MM-DD antes de cruzar las bases.
- **Cartera con 122 IDs "CAND-PH"** (551 filas) que no existen en las solicitudes, y 70 solicitudes sin desembolso que no tienen cartera ni se pueden etiquetar. Quedan 3.930 créditos.
- **Saldo de capital que baja aun estando en mora** (por ejemplo CAND-00139), por lo que no lo usé como variable.
- **Transiciones sin permanencia:** nadie se queda en mora 30 ni en 60; o se cura o rueda.
- **Efecto invertido del buró:** tener buró aumenta el default (13.8% contra 6.1% en train; 22.2% contra 6.9% en test), y bureau_score no ordena el riesgo entre quienes lo tienen (AUC 0.509 en train y 0.422 en valid).
- **434 créditos (11%) en mora ≥30 desde el primer corte:** 54.4% termina en default y son el 57% de los 415 eventos. Sospecho fraude o no pago inicial.
- **Cambio de población en octubre 2024:** el pago a tiempo de servicios cae de 0.75 a 0.67 de un mes a otro y el default pasa de unos 9% a 12.4% (oct), 14.7% (nov) y 14.0% (dic).
- 48 ingresos corruptos (quedaron nulos) y cuatro variables con colas muy largas.

3. ¿Qué variables fueron más predictivas y hay poblaciones distintas?

Usé el IV frente a un **piso de ruido** (IV de la variable con el objetivo barajado) y verifiqué que se repitiera en valid con el WoE de train. Solo tres superaron ambos controles:

Variable	IV train	IV valid	AUC valid	KS valid	Piso ruido
avg_monthly_topups	0.435	0.407	0.686	0.321	0.043
has_bureau_record	0.193	0.227	0.629	0.258	0.015
pago_prom (servicios + telco)	0.146	0.207	0.652	0.244	0.054

Sentido de negocio. Las recargas miden flujo de dinero y uso real del producto: el sexto de clientes con menos recargas tiene 20.6% de default y el sexto con más, 3.2% (train). El pago puntual de servicios es un buen sustituto del historial de crédito. Retiré 10 variables (edad, ingreso declarado, antigüedad, transacciones, % P2P, engagement, monto, dispositivo, producto, sexo): su IV no supera el ruido o no se replica en valid; sumarlás baja el AUC de valid de 0.781 a 0.729.

Poblaciones distintas: (1) sin buró (55%, default ~6%) y con buró (45%, 14% a 22%); (2) los 434 créditos en mora desde el primer corte; (3) los solicitantes desde octubre 2024, con peor pago. Los tres productos tienen tasas casi iguales (15.4% a 15.9% de "alguna vez ≥60").

4. Tasa de default, desbalance, técnica y métricas

La tasa de default es **10.6%** (415 de 3.930): 9.6% en train, 10.8% en valid y 14.4% en test. Es un desbalance moderado.

- **Técnica:** regresión logística sobre WoE sin pesos de clase. Probé class_weight=balanced: mismo AUC (0.782) y KS (0.461), pero la PD media

predicha pasa de 9.9% a 43.7% con una tasa real de 10.8%, lo que arruina la calibración. Como el uso es fijar políticas con la PD, no rebalanceo.

- **Métricas:** AUC y KS para ordenar, **PR-AUC** (0.312 en valid contra 0.108 de azar) porque sí depende de la tasa, Brier y calibración por decil.

Si fuera 3%. Simulé descartando eventos hasta 3% (20 repeticiones): AUC 0.770 y KS 0.481 casi no cambian, pero el **PR-AUC cae de 0.312 a 0.128** y en train quedarían 74 eventos. En ese caso usaría menos bins (3 o 4) o regularización, ampliaría la ventana o reuniría más cohortes para tener más eventos, validaría con validación cruzada temporal y reportaría precisión y recall en el corte de operación, no solo AUC. Para boosting sí usaría pesos o submuestreo, con recalibración posterior.

5. KS y AUC en validación

AUC y KS en valid (631 créditos, 68 eventos); en variables, mayor puntaje = menor riesgo salvo has_bureau_record:

Variable / modelo	AUC valid	KS valid	AUC test	KS test
avg_monthly_topups	0.700	0.363	0.723	0.355
pago_prom	0.660	0.278	0.580	0.186
has_bureau_record	0.629	0.258	0.656	0.311
bureau_score (con buró)	0.422	0.252	0.484	0.106
Score del modelo	0.781	0.461	0.777	0.473

Lectura. Ninguna variable supera AUC 0.72, pero juntas llegan a 0.78 porque miden aspectos distintos (VIF 1.0). Entre train (0.750), valid y test (0.777; IC95% 0.730 a 0.821) no hay sobreajuste. bureau_score no aporta: su KS de 0.252 en valid no se repite en train (0.059) ni en test (0.106).

Rango aceptable para un piloto: AUC 0.70 a 0.80 y KS 0.30 a 0.45, el rango que suelen tener los modelos con datos alternativos en clientes sin historial; por debajo de 0.65 de AUC o 0.25 de KS no hay poder para decidir y por encima de 0.85 sospecharía de fuga de información. Un piloto es controlado, tiene exposición limitada y permite corregir; en un lanzamiento masivo exigiría más. Mi modelo (0.78 y 0.47) está dentro del rango, con límite inferior de IC (0.73) todavía aceptable.

6. PSI entre particiones

- **Score del modelo:** PSI train vs valid **0.020** (estable) y train vs test **0.142** (moderado; el 32.7% de test cae en los dos deciles más riesgosos contra 18.7% en train).
- **Variables:** estables (PSI < 0.03), como recargas (0.014 y 0.013) y buró (0.005 y 0.004), salvo las de pago de servicios: pago_prom 0.116 (valid) y **0.452** (test); utility_payment_ontime_rate 0.094 y **0.773**; telco_ 0.061 y 0.291.

Decisión. No aprobaría el modelo "tal cual", pero tampoco lo descartaría. El corrimiento es real (la gente paga peor desde octubre, no es un error de datos) y el modelo mantiene el orden (AUC 0.777 en test), pero subestima el nivel de riesgo (PD media 12.5% frente a 14.4% real). Aprobaría su uso en el piloto con tres condiciones: (a) **recalibrar el nivel** con datos recientes, lo que en test lleva la PD media a 14.3% sin tocar el AUC; (b) fijar el corte con la PD recalibrada, no con la de entrenamiento; (c) monitoreo mensual con alerta de PSI > 0.10 y plan de reentrenamiento si supera 0.25.

7. Tratamiento del segmento sin historial de buró

Es el 55% de los créditos (1.451 en train) y es el segmento del piloto, así que **no lo separé ni lo imputé**: un solo modelo con `has_bureau_record` como bandera. Razones:

- `bureau_score` es nulo exactamente cuando `has_bureau_record` es falso; imputarlo con un promedio inventaría información. El nulo es una categoría con significado.
- Las variables alternativas ordenan el riesgo en ambos segmentos: dentro de los clientes sin buró el default baja de 13.5% a 1.9% del primer al cuarto cuartil de recargas, y en valid el AUC es 0.680 (recargas) y 0.734 (pago de servicios).
- Probé `bureau_score` con el nulo en neutro (modelo B): AUC 0.771 contra 0.781, diferencia -0.010 (IC95% -0.022 a +0.001), así que lo descarté.

Resultado en test: AUC 0.792 y KS 0.563 sin buró (23 eventos) contra AUC 0.695 y KS 0.312 con buró (70 eventos). El modelo funciona mejor justo donde más se necesita. La salvedad es que `has_bureau_record` tiene signo contrario al intuitivo (más default con buró, 13.8% contra 6.1%) y no entiendo del todo por qué; antes de usarlo como regla de negocio habría que investigar la selección de esos clientes.

8. Tres riesgos operativos para llevarlo a producción

- **Deriva de la población y del nivel de riesgo.** Ya ocurrió, desde octubre 2024 el PSI de las variables de pago llega a 0.45 y el del score a 0.142. **Cómo:** monitoreo mensual (PSI por variable y score, default por cohorte de originación, calibración por decil) en un job programado con alertas; recalibración periódica del intercepto y plan de reentrenamiento con ventana móvil. Como la etiqueta madura en 90 días, alertar antes con PSI y mora del primer corte.
- **Calidad y disponibilidad de los datos al momento de calcular.** Las fechas llegaron con formatos mezclados (DD-MM-AAAA, D/MM/AA); los pagos de servicios tienen 6% de nulos y en `bureau_score` el 54.7% es nulo por diseño. **Cómo:** validación de esquema y rangos en el pipeline (fechas, nulos, rangos), reglas explícitas para nulos (el bin NULO ya está en el modelo), y rechazo de lotes que no cumplan. El modelo se guarda como un JSON con bins, WoE y coeficientes; la función de scoring reproduce las PD del modelo con diferencia de $1e-16$ y debe cubrirse con pruebas unitarias.
- **Fraude y sesgo de muestra.** El 11% de los créditos entra en mora desde el primer corte (54.4% default) y el modelo solo conoce a los 3.930 desembolsados; no hay información de los 70 rechazados. **Cómo:** capa antifraude y de primer pago antes del scoring, el score como una señal más, y registrar las decisiones y los clientes rechazados desde el inicio del piloto para poder inferir rechazados y reentrenar sin sesgo. Versionar modelo, datos y código, y desplegar primero en modo sombra.

9. Fuera de alcance y qué haría con una semana más

Quedó fuera por tiempo:

- **Optimización fina:** no ajusté hiperparámetros del boosting ni probé otros modelos (por ejemplo, regularización o monotonidad), el boosting empató con la logística (AUC +0.003, IC95% -0.032 a +0.039), así que no era prioritario.
- **Tratamiento separado del fraude temprano:** dejé los 434 créditos en mora desde el primer corte dentro del default y solo medí la sensibilidad (AUC en valid 0.762 sin ellos).

- **Validación más robusta:** solo hay un corte temporal y 93 eventos en test; los IC son amplios.
- **Inferencia de rechazados** (70 sin desembolso), **análisis de equidad** por sexo (incluida la categoría NB) y **política de corte económica**, que requeriría margen, pérdida dada el incumplimiento y saldo.

Con una semana adicional: (1) validación temporal con varias ventanas (rolling) para cuantificar la inestabilidad del AUC, (2) modelo o regla para el fraude temprano y evaluar el score sin él, (3) investigar por qué el buró tiene efecto contrario y si hay otro tipo de poblaciones, (4) recalibración y política de corte con costos, (5) crear el pipeline de monitoreo y control del modelo.

10. Uso de IA

Si, usé **NotebookLM** para la parte de investigación y asesoría sobre papers, entradas en blogs de ciencia de datos y estado del arte de los modelos de default, scoring o riesgo de crédito, esto me ayudó a orientarme un poco más sobre lo que pasa usualmente con modelos difíciles de calibrar y la interpretación de algunas variables. También use **Claude Code** para acelerar la parte de generación de gráficas, filtros, estandarización de data y generación de test de unicidad, sin embargo y como pueden ver en el notebook final todo se encuentra hecho paso a paso de tal forma que cada paso era consecuencia del anterior y en ningún momento la IA generó el modelo vibe-codeado dado que en todo momento estuve tomando las decisiones sobre a dónde encaminar el ejercicio de modelamiento de acuerdo a los resultados que iban surgiendo.